PANDUAN METODE NICHE ARSENAL TEKS
GEMASTIK XIX Penambangan Data

Kapan dipakai dan untuk data seperti apa

Tujuh notebook di `contoh/text/` pada panduan ini adalah lapis kedua. Notebook ini tidak menggantikan baseline dan baru dipakai setelah model dasar berjalan dan menulis OOF (`klasifikasi_tfidf`, `baseline_oof`, `teks_tabular`, `finetune_oof`). Peta soal ke notebook ada di `contoh/PANDUAN.md`.

1. Aturan Main

Aturan berikut berlaku untuk ketujuh notebook.

1. **Pakai hanya kalau skor jujur naik.** Tiap notebook mencetak skor jujur (lipatan luar atau holdout) dan memilih cara paling sederhana yang selisihnya $\leq$ `MIN_GAIN` dari yang terbaik. Ikuti pilihan itu. Di demo, cara rumit sering menang di OOF lalu kalah di test.
2. **Semuanya untuk target kelas.** Target angka memakai `ensemble_oof`, `stacking_teks_tabular_regresi`, dan `interval_prediksi`.
3. **Metrik harus "makin besar makin baik".** Untuk logloss, RMSE, dan MAE, tulis `return -(...)`.
4. **Hapus sel bertanda `HAPUS saat lomba`.** Yang paling berbahaya adalah sel "OOF demo" di `bobot_ensemble_metaheuristik` dan `stacking_fwls` yang berisi `OOF_FOLDER = OUTPUT_FOLDER`. Kalau lupa dihapus, notebook melatih model demo dan membaca OOF itu, bukan OOF milik sendiri.
5. Data demo kecil (emot 3,9 ribu baris, baju 17,6 ribu baris). Selisih $< 0{,}005$ pada data sekecil itu masih bisa berupa derau. Kemenangan penting dicek dengan `uji_beda_model`.
6. Batas angka seperti "$\geq \pm 5.000$ baris" atau "kelas $\leq \pm 10$" adalah perkiraan, bukan hasil uji. Skor jujur di notebook tetap yang menentukan.

2. Pilih Cepat

Tabel 1 memetakan keadaan data atau model ke notebook yang dibuka.

Tabel 1: Keadaan data dan notebook yang dibuka

Keadaan data / model	Buka	Syarat minimum
≥ 3 OOF, metrik berundak (F1 makro, akurasi, QWK), ingin bobot lebih baik dari rata-rata	`bobot_ensemble_metaheuristik`	file `oof_/test_` dari lipatan yang sama

Keadaan data / model	Buka	Syarat minimum
Kualitas anggota timpang, atau model unggul di jenis baris berbeda (teks pendek vs panjang, kolom kosong)	`stacking_fwls`	≥ 2 OOF dan kolom angka untuk ciri baris
Ensemble mentok karena semua anggota TF-IDF + linear (korelasi $> 0{,}95$)	`pengklasifikasi_alternatif`	teks
Teks + tabel untuk LightGBM, tidak ada waktu merancang fitur	`fitur_otomatis_tetangga`	kolom angka/kategori
Fitur buatan banyak (> 30), curiga derau, perlu slide "fitur penting"	`seleksi_fitur_metaheuristik`	target biner
Label sedikit, teks tanpa label banyak	`co_training_teks` (juga `graf_label_teks`, `semi_supervised_teks`)	teks $\geq$ beberapa kata
Juri butuh penjelasan "JIKA ... MAKA"	`rulefit_aturan`	biner (multikelas: 1 lawan sisa)

3. Kartu per Notebook

Setiap kartu berisi data yang cocok, kapan notebook tidak dipakai, cara membaca hasil, hasil demo, dan bagian yang perlu diganti saat lomba.

3.1 Bobot Gabungan tanpa Turunan

Notebook: `bobot_ensemble_metaheuristik`.

- **Bagus untuk:** klasifikasi dengan metrik berundak (F1 makro, akurasi, QWK) yang membuat Nelder-Mead/SLSQP macet; 4–8 model yang skornya berdekatan; train $\geq \pm 5.000$ baris.
- **Jangan dipakai kalau:** hanya 2 model (cukup rata-rata di `ensemble_oof`); satu model jauh lebih unggul (bobot lari ke satu model); metrik halus seperti logloss/AUC (cukup Nelder-Mead di `ensemble_oof`); data < 2.000 baris (bobot cocok ke derau).
- **Pilih cara:** lihat Tabel 2.
- **Baca:** kolom `skor jujur`, bukan `skor OOF (optimis)`. Selisih keduanya menunjukkan besar overfit bobot.
- **Demo (emot, 5 model, 1 menit):** rata-rata 0,675 naik menjadi 0,685 (skor jujur hill negatif). Di test justru hill biasa terbaik (0,674 vs 0,664). Untuk data < 5.000 baris, naikkan `MIN_GAIN` ke 0,005.
- **Ganti:** `MODELS`, `metric`, dan hapus sel OOF demo.
- **Untuk juri:** "F1 makro tidak bisa diturunkan, jadi bobot dicari dengan metaheuristik dan dinilai di lipatan yang tidak dipakai mencari bobot."

Tabel 2: Pilihan cara mencari bobot

Cara	Pakai kalau
Hill (Caruana)	bawaan; paling tahan overfit karena bobot berupa hitungan langkah
Hill negatif	ada model yang salahnya bisa "dikurangkan"; butuh data besar
Annealing	hill macet di bobot yang sama
Evolusi diferensial / genetik	lebih dari 6 model, ruang bobot besar
Optuna	perlu jejak percobaan; hasilnya mirip evolusi

3.2 Bobot yang Berubah Menurut Ciri Baris (FWLS)

Notebook: `stacking_fwls`.

- **Bagus untuk:** teks + kolom angka; panjang teks sangat beragam; ada kolom teks yang sering kosong; anggota punya kekuatan berbeda (huruf, kata, judul saja, tabular). Train $\geq \pm 5.000$ baris karena koefisien FWLS berjumlah model $\times$ kelas $\times$ ciri.
- **Jangan dipakai kalau:** anggota mirip semua; data kecil; tidak ada ciri baris yang bermakna.
- **Baca:** `skor_per_panjang.png`. Garis model yang bersilangan antar kelompok panjang berarti FWLS layak. Garis yang sejajar berarti stacking LR biasa sudah cukup.
- **Demo (baju rating 5 kelas, 4 model, ±1,5 menit):** hasil pada Tabel 3. Rata-rata merusak karena model tabular lemah (0,159). Kalau anggota timpang, stacking apa pun jauh di atas rata-rata. FWLS sendiri tidak menang di demo ini.
- **Ganti:** `MODELS`, `TEXT_COLS`, `META_COLS` (kolom yang menggambarkan *jenis* baris, bukan yang paling kuat menebak target), dan hapus sel OOF demo.

Tabel 3: Hasil demo `stacking_fwls` (F1 makro)

Cara	Skor jujur	Skor test
Model tunggal terbaik	0,434	0,435
Rata-rata	0,357	0,359
Stacking LR (dipilih)	**0,496**	**0,509**
FWLS	0,493	0,490
LightGBM + ciri	0,483	0,497

3.3 Anggota Ensemble yang Salahnya Berbeda

Notebook: `pengklasifikasi_alternatif`.

- **Bagus untuk:** teks saja, ketika ensemble sudah ada tetapi semua anggotanya TF-IDF + linear. Teks pendek penuh typo/alay cocok dengan gzip-kNN dan kernel RFF. Dokumen panjang yang mirip pen-

carian cocok dengan BM25-kNN dan Rocchio. Kelas tidak seimbang cocok dengan Complement NB.
- **Jangan dipakai kalau:** sudah ada fine-tune transformer yang kuat (tambahan jarang membantu); data > 20 ribu baris untuk gzip (lambat).
- **Baca:** kolom `+ patokan` adalah skor rata-rata model itu dengan patokan; ambil yang di atas patokan. Kolom `korelasi` makin kecil berarti makin beragam. Kolom `menyelamatkan` adalah porsi baris yang salah di patokan tetapi benar di model ini. Keputusan akhir diambil di `ensemble_oof` atau `bobot_ensemble_metaheuristik`.
- **Demo (emot, 1,5 menit):** sendirian semuanya kalah (gzip 0,365, terbaik passive-aggressive 0,675 vs patokan 0,679). Dirata-rata dengan patokan, OOF naik (RFF 0,687, Rocchio 0,684) tetapi test tidak. Perlakukan sebagai calon anggota, bukan model utama.
- **Waktu:** gzip sebanding dengan baris × `NCD_POOL` (3,9 ribu baris ≈ 1 menit, 20 ribu ≈ 5 menit). Kecilkan `NCD_POOL` kalau lambat.
- **Hasil:** `oof_alt_*.npy` di `OOF_FOLDER`, langsung ditulis di `MODELS` notebook ensemble.

3.4 Fitur Tetangga kNN dan OpenFE Mini

Notebook: `fitur_otomatis_tetangga`.

- **Bagus untuk:** teks + tabel untuk LightGBM, dengan kategori bernilai banyak dan kolom angka yang bisa digabung (rasio, selisih terhadap rata-rata kelompok).
- **Jangan dipakai kalau:** teks saja; sudah memakai `stacking_teks_tabular` (sudah punya fitur tetangga, jadi ambil kolom otomatisnya saja).
- **Baca:** `banding_fitur.csv` (dasar, + tetangga, + otomatis, + keduanya). Untung fitur otomatis yang kecil itu normal.
- **Demo (baju biner, 30 detik):** AUC 0,906 naik menjadi 0,914 dengan fitur tetangga dan 0,916 dengan keduanya. Fitur otomatis terbaik adalah `title_huruf/title_kata` (rata-rata panjang kata judul).
- **Pakai hasilnya:** `fitur_baru_train.csv` dan `fitur_baru_test.csv` (ada `ID_COL`, urutan baris sama dengan file asli), lalu `pd.concat` kolomnya ke notebook LightGBM.
- **Belum diuji:** multikelas (kodenya ada).

3.5 Membuang Fitur Derau

Notebook: `seleksi_fitur_metaheuristik`.

- **Bagus untuk:** lebih dari 30 fitur buatan (SVD, statistik teks, enco-

ding, agregat); $\geq$ 5.000 baris; ingin model lebih ramping atau cepat; bahan slide "fitur mana yang penting dan bukti sisanya derau".
- **Jangan dipakai kalau:** fitur $<$ 20; ribuan kolom TF-IDF (terlalu lambat, pakai chi^2 atau L1); target multikelas atau angka (notebook ini biner saja); sisa waktu $<$ 30 menit.
- **Pilih cara:** lihat Tabel 4.
- **Demo (baju biner, 48 fitur termasuk 10 kolom acak, 1 menit):** semua cara membuang 10 kolom acak, tetapi holdout tidak naik (semua fitur 0,9066, permutasi 0,9067), sehingga notebook tetap memilih semua fitur. LightGBM sudah tahan derau, jadi gunanya terutama untuk penjelasan dan kecepatan.

Tabel 4: Pilihan cara seleksi fitur

Cara	Sifat
Null importance	cepat; grafiknya bagus untuk slide
Boruta	paling ketat (membuang paling banyak)
Permutasi	paling lunak
Annealing / genetik	mencari kombinasi; paling mahal, untuk 30–100 fitur

3.6 Semi-supervised Dua Sudut Pandang

Notebook: `co_training_teks`.

- **Bagus untuk:** label ratusan sampai ±2 ribu, teks tanpa label jauh lebih banyak (test besar atau file tambahan), kelas $\leq \pm 10$.
- **Jangan dipakai kalau:** label sudah banyak ($> \pm 50\%$ data) karena untungnya hilang; teks hanya 1–3 kata sehingga sudut pandang kata dan huruf tidak lagi saling melengkapi; test bergeser dari train (cek `geser_distribusi`) karena label palsu yang salah akan menumpuk.
- **Pilih notebook:** lihat Tabel 5.
- **Demo (emot, 15% label = 544 baris, 25 detik):** hasil pada Tabel 6. Ambang keyakinan sederhana mudah merusak; jumlah tetap per kelas lebih aman.
- **Ganti:** `LABEL_SHARE = 1.0` saat lomba (0,15 hanya untuk demo). Baris train bertarget kosong otomatis masuk kolam tak berlabel. File teks tambahan tanpa label diisi di `UNLABELED_CSV`.

Tabel 5: Pilihan notebook semi-supervised

Notebook	Cocok kalau
`co_training_teks`	ada dua sudut pandang (kata vs huruf, teks vs tabel)
`graf_label_teks`	teks membentuk kelompok/topik yang jelas, test besar
`semi_supervised_teks`	kelas banyak; pseudo-label N teratas per kelas

Tabel 6: Hasil demo `co_training_teks` (F1 makro)

Cara	OOF berlabel	Skor test
Hanya label	0,548	0,557
Self-training	0,493	0,511
Co-training (dipilih)	**0,569**	**0,578**
Tri-training	0,519	0,540

3.7 Aturan "JIKA ... DAN ... MAKA" untuk Slide

Notebook: `rulefit_aturan`.

- **Bagus untuk:** presentasi ke juri non-teknis; target biner atau satu kelas penting; campuran kata kunci dan kolom tabel.
- **Jangan dipakai kalau:** sebagai model utama (CV di bawah LightGBM); multikelas dengan banyak kelas (buat satu per kelas penting saja).
- **Baca:** `aturan_teratas.png`. Biru menaikkan peluang, oranye menurunkan. Aturan "TIDAK kata:x DAN TIDAK kata:y" berarti kata-kata negatif tidak muncul, biasanya ulasan positif. Untuk slide, pilih 3–5 aturan dengan `porsi baris` 5–60%. Aturan yang berlaku untuk 95% baris kurang bercerita.
- **Demo (baju biner, 22 detik):** AUC CV RuleFit 0,873, LightGBM 0,877, L1 0,879; 53 aturan terpakai dari 556; test 0,881.
- **Ganti:** `POSITIVE`, `STOP_WORDS` (`None` atau daftar stopword Indonesia), dan `RULE_C` (makin kecil, aturan makin sedikit).

4. Alur Gabungan yang Disarankan

Teks saja, multikelas.

1. TF-IDF dan fine-tune menulis OOF.
2. `pengklasifikasi_alternatif` untuk mencari anggota yang berbeda.
3. `ensemble_oof`.
4. Kalau metrik F1/QWK dan ada ≥ 4 model: `bobot_ensemble_metaheuristik`.
5. `uji_beda_model` untuk memastikan kemenangan bukan derau.

Teks + tabel, biner.

1. `teks_tabular` atau `stacking_teks_tabular`.
2. `fitur_otomatis_tetangga`.
3. `seleksi_fitur_metaheuristik`.
4. LightGBM final.
5. `rulefit_aturan` dan `penjelasan_teks` untuk slide.

Teks + tabel, multikelas, anggota timpang. Beberapa OOF diga-

bung di `stacking_fwls`.

Label sedikit. `co_training_teks` dan `graf_label_teks`, lalu OOF keduanya digabung di `ensemble_oof`.

5. Urutan saat Waktu Sempit

Tabel 7 mengurutkan langkah menurut untung di demo.

Tabel 7: Urutan langkah menurut untung demo

No	Langkah	Untung demo	Waktu demo	Kapan
1	Stacking LR saat anggota timpang (`stacking_fwls` atau `ensemble_oof`)	+0,06 F1 vs model terbaik	±1,5 menit	selalu dicoba
2	Fitur tetangga (`fitur_otomatis_tetangga`)	+0,008 AUC	30 detik	selalu dicoba
3	Co-training	+0,02 F1	25 detik	hanya kalau label sedikit
4	Bobot metaheuristik, seleksi fitur, pengklasifikasi alternatif	kecil/tidak stabil	1–1,5 menit	sisa waktu > 1 jam
5	RuleFit	–	22 detik	khusus bahan slide

Semua waktu di atas diukur di laptop dengan data demo (4–18 ribu baris). Data 5× lebih besar kira-kira 5× lebih lama; gzip-kNN serta annealing/genetik bisa lebih lama lagi.