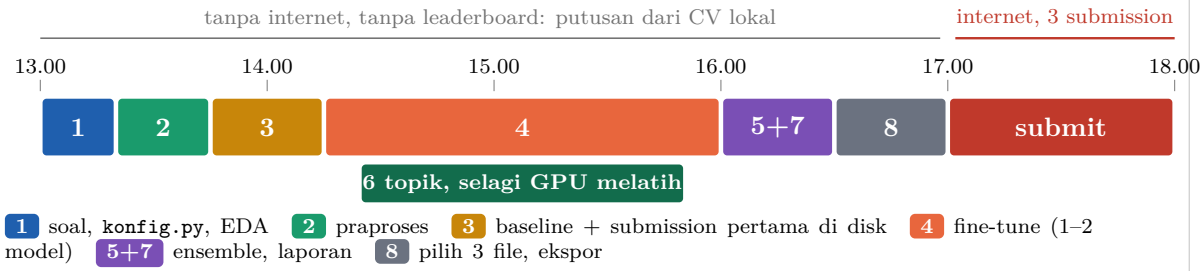
Petunjuk Akhir: final-pipeline

GEMASTIK XIX Penambangan Data • Rabu, 11 November 2026 • 13.00–18.00

Tebakan soal: **klasifikasi teks** (skor di Kaggle) dan **topic modeling** (dipresentasikan). Delapan langkah bernomor, satu file konfigurasi.

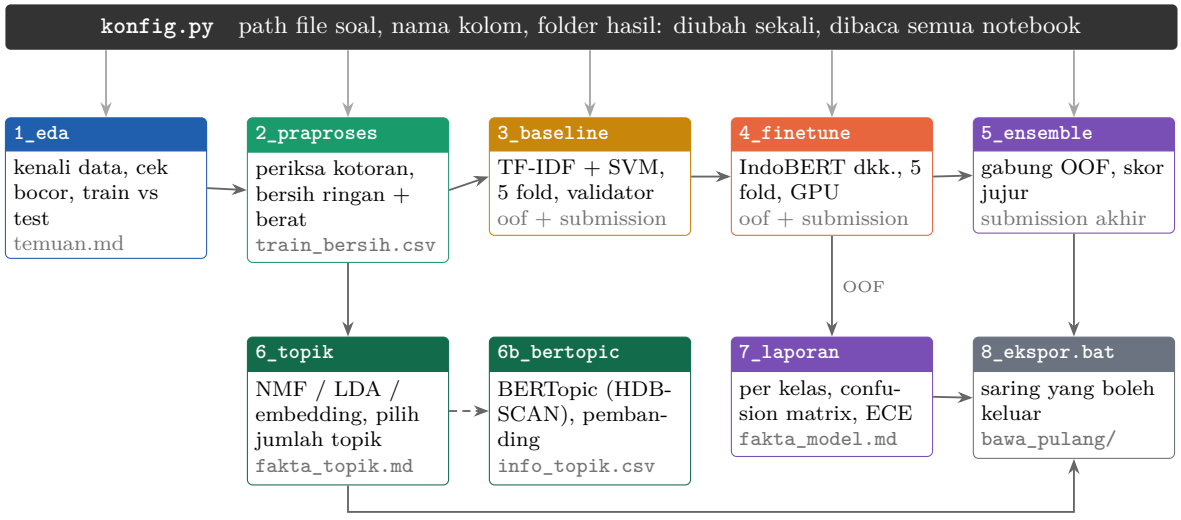
Gambar 1. Lima jam dalam satu garis (rencana, bukan aturan panitia)



1 Peta pipeline

Folder `final-pipeline` berisi salinan tujuh notebook repo yang sudah teruji, diberi nomor urut. Kodenya sama dengan `contoh/text/`; yang berbeda hanya path dan sel Konfigurasi, yang sekarang membaca `konfig.py`. Jalankan menurut nomor.

Gambar 2. Alur file dari soal sampai bahan presentasi



Gambar 3. Susunan folder yang wajib (path di notebook relatif)

```
C:/GEMASTIK/
  not-a-super-secret-weapon/   repo
    final-pipeline/   folder ini
      konfig.py
      1_eda.ipynb ... 7_laporan_model.ipynb
      8_ekspor.bat, jupyter.bat
      demo/, kamus/
  pretrained/   model (download_model.bat)
  .venv/   dibuat setup.bat
  outputs/final/   semua hasil
```

Buka: dobel klik `jupyter.bat` di folder ini.

Tidak butuh `data_latihan`: data demo dan kamus alay sudah ikut di sini.

Folder ini **ada di dalam repo**, jadi ikut `git clone` / `git pull`.

2 Yang diubah saat soal dibuka

Hanya `konfig.py`. Sesudah menyimpan, di tiap notebook pilih *Restart Kernel and Run All*.

```
TRAIN_MENTAH = "C:/GEMASTIK/soal/train.csv"                    wajib
TEST_MENTAH  = "C:/GEMASTIK/soal/test.csv"                     wajib
SAMPLE_PANITIA = "C:/GEMASTIK/soal/sample_submission.csv"      wajib
ID_COL = "id"    TEXT_COLS = ["text"]    TARGET = "label"      wajib
SUBMIT_COL = TARGET                    bila nama di sample beda
HASIL = "../../outputs/lomba"          ganti dari "final"
LANGUAGE, DATE_COL, GROUP_COL, TFIDF_BERAT   bila perlu
```

Tiga hal yang tidak ada di `konfig.py`.

1. **Metrik.** Bawaannya F1 makro. Kalau soal memakai metrik lain, pindahkan `#` di baris `return` sel "Metrik" pada `3_baseline`, `4_finetune`, dan `5_ensemble` (ketiganya harus sama).
2. **Pemisah dan encoding CSV.** Kalau `pd.read_csv` gagal atau kolom jadi satu, pakai baris ber-`#` di sel "Baca data" `2_praproses` (`sep=";"`, `encoding="latin-1"`). Notebook 3–7 membaca `train_bersih.csv`, jadi cukup dibetulkan di notebook 1 dan 2.
3. **Pola awalan/akhiran.** `STRIP_PATTERNS` di `2_praproses` masih pola demo. Isi dari tabel "Awalan dan akhiran berulang" di notebook itu, atau kosongkan (`[]`).

3 Langkah demi langkah

Waktu di pojok kanan diukur pada gladi 10 November 2026 di laptop (RTX 5060 8 GB) dengan data demo SmSA: 11.000 teks latih, 3 kelas. Data lomba yang lebih besar atau lebih panjang akan lebih lama.

`1_eda` — demo 23 s

Tujuan	Tahu bentuk data sebelum memilih apa pun. Tidak mengubah file.
Lihat	Sebaran kelas, panjang teks, teks kembar dan kembar beda label, kekuatan tiap kolom (tanda bocor), AUC adversarial train vs test.
Luaran	`eda/temuan.md` dan PNG. `AMAN_NDA = True`: tidak mencetak teks asli.

2_praproses — demo 60 s

Tujuan Membuat `train_bersih.csv` dan `test_bersih.csv` yang dibaca semua notebook sesudahnya.

Ubah `STRIP_PATTERNS`; saklar `DROP_*` di bagian 7 (teks kembar beda label).

Lihat Tabel "Ukur": langkah mana yang menaikkan skor. Tiga baris `CEK` di sel terakhir harus `True`.

Awas Jumlah baris train bisa berkurang (kosong, kembar). Jangan jalankan ulang notebook ini sesudah ada OOF, kecuali semua model dilatih ulang.

3_baseline — demo 24 s, F1 OOF 0,860

Tujuan Submission pertama yang sah dan OOF pertama. Target: selesai sebelum 14.15.

Ubah `MODEL_NAME` tiap variasi (mis. `tfidf_logreg`), lalu pindahkan `#` di `CLASSIFIER`. Nama sama berarti OOF lama tertimpa.

Lihat Skor OOF dan baris terakhir validator: `MASALAH: 0`. Tulisan `PERINGATAN: SAMPLE_CSV masih file demo` berarti `SAMPLE_PANITIA` belum diisi.

Luaran `baseline/submission.csv`, `oof/oof_<nama>.npy`, `oof/percobaan.csv`.

4_finetune — demo 31 s per epoch per fold; 1 epoch F1 OOF 0,927

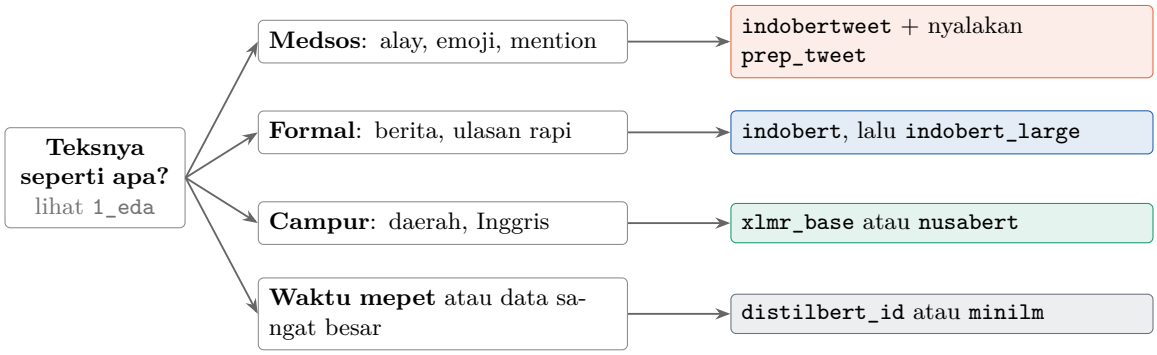
Tujuan Skor tertinggi. Zero-shot dan few-shot dilarang; fine-tune sendiri seperti ini boleh.

Ubah `PRETRAINED` + `MODEL_NAME` (Gambar 4); `MAX_LENGTH` dari tabel persentil token (ambil sekitar p95).

Uji dulu `FOLDS_TO_RUN = [0]` untuk mengukur waktu satu fold (OOF tidak disimpan), lalu kembalikan ke `None`. Waktu penuh kira-kira 5 kali satu fold. Gladi memakai 1 epoch (3 menit); bawaan 3 epoch, jadi kira-kira 8 menit di data demo.

Awas GPU hanya untuk satu notebook fine-tune pada satu waktu. Model *large*: `BATCH_SIZE = 8`, `ACCUM_STEPS = 2`, `GRAD_CHECKPOINT = True`.

Gambar 4. Memilih `PRETRAINED` di `4_finetune`



Dua model yang berbeda (mis. `indobert` dan `xlmr_base`) lebih berguna untuk ensemble daripada satu model dengan dua seed.

5_ensemble — demo 5 s

Tujuan Menggabung semua OOF di `oof/` dan menilai dengan skor jujur (bobot dicari di lipatan lain).

Lihat Sel "Putusan". Gabungan hanya dipakai bila naik sekurangnya `MIN_GAIN` (0,002); kalau tidak, notebook memilih model tunggal terbaik. Ikuti putusannya.

Luaran `ensemble/submission.csv`, `ablation.csv` (bahan slide).

6_topik dan 6b_topik_bertopic — demo 5 menit dan 80 s

Tujuan	Topic modeling untuk presentasi. `6_topik` membandingkan NMF, LDA, dan embedding+KMeans pada beberapa jumlah topik dengan koherensi NPMI, keragaman, dan kestabilan, lalu memilih sendiri.
Ubah	`EXTRA_STOPWORDS` (kata umum yang mengotori topik), lalu `TOPIC_NAMES` sesudah membaca kata teratas. `TOPIC_COUNTS` bila jumlah topik yang wajar jauh dari 4–15.
Kapan	Selagi `4_finetune` berjalan. NMF dan LDA memakai CPU. Metode `"embedding"` dan `6b` memakai MiniLM di GPU; bila VRAM penuh, hapus `"embedding"` dari `METHODS` dulu.
Luaran	`topik/fakta_topik.md`, grafik kata teratas, topik × kelas, peta 2D. `6b` hanya pembanding: BERTopic menentukan jumlah topik sendiri dan menyisakan topik −1.

7_laporan_model — demo 7 s

Tujuan	Bahan slide hasil klasifikasi dari OOF, tanpa GPU: skor tiap model, laporan per kelas, confusion matrix, pasangan kelas tertukar, keandalan (ECE).
Luaran	`laporan/fakta_model.md` dan 10 grafik. Jalankan sesudah model terakhir selesai.

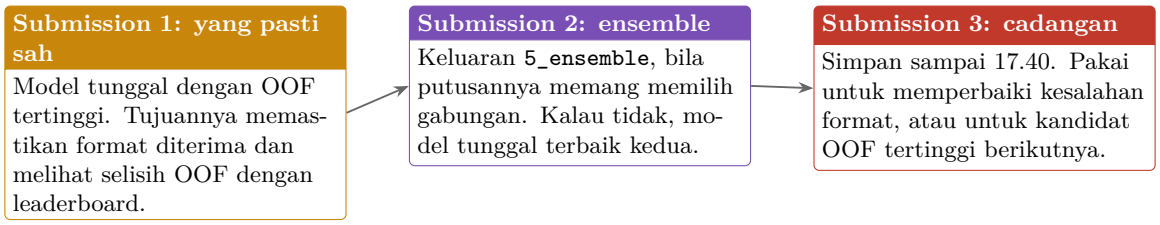
8_ekspor.bat — beberapa detik

Tujuan	Menyalin yang boleh keluar ke `outputs/bawa_pulang/` dan menolak sisanya.
Ubah	Baris `set "HASIL=..."` bila `HASIL` di `konfig.py` diganti.
Lihat	`MANIFEST.md`: daftar yang disalin, yang ditolak, dan alasannya.

4 Jam terakhir: tiga submission

Empat jam pertama tidak ada leaderboard. Pilih file dari skor OOF dan dari validator, bukan dari perasaan.

Gambar 5. Urutan tiga submission (saran)



Sebelum mengunggah tiap file:

☐ validator di notebook penghasilnya menulis `MASALAH: 0` dan tidak ada `PERINGATAN: SAMPLE_CSV masih file demo`;

☐ jumlah baris dan urutan id sama dengan sample panitia (dicek validator);

☐ sebaran kelas prediksi masuk akal, tidak satu kelas saja (dicetak validator);

☐ nama file dan nama kolom persis seperti yang diminta soal.

Leaderboard publik hanya sebagian data test. Selisih kecil di sana belum tentu nyata; kalau OOF dan leaderboard tidak sepakat untuk selisih kecil, pegang OOF.

5 Yang boleh keluar dari PC lomba

Boleh dibawa

- PNG grafik dan tabel ringkas
- `temuan.md`, `fakta_topik.md`, `fakta_model.md`
- notebook, file submission, model
- screenshot

Semuanya dikumpulkan `8_ekspor.bat`.

Dilarang keluar

- teks asli atau baris data
- `train_bersih.csv`, `test_bersih.csv`
- file per baris: OOF (`.npy`), `topik_dokumen.csv`, `pseudo_label.csv`
- output sel yang mencetak teks

Slide dibuat di laptop tanpa akses data, jadi setiap angka yang ingin disebut harus sudah ada di tiga file `.md` di atas atau di PNG. Kalau ada angka yang kurang, tambahkan ke notebook *sebelum* meninggalkan PC lomba.

6 Kalau macet

Gejala	Tindakan
`CUDA out of memory`	`BATCH_SIZE = 8` dan `ACCUM_STEPS = 2`; kecilkan `MAX_LENGTH`; tutup kernel notebook lain yang memakai GPU (termasuk `6_topik`).
`device: cpu` di `4_finetune`	Driver NVIDIA belum cocok (torch cu128 butuh driver 570 ke atas). Selagi diperbaiki, kerjakan variasi `3_baseline`.
Satu fold terlalu lama	`distilbert_id` atau `minilm`; `EPOCHS = 2`; `PATIENCE = 2` dengan `EVALS_PER_EPOCH = 2`.
`TIDAK ADA OOF YANG COCOK`	OOF dibuat dari train yang lain: `2_praproses` dijalankan ulang atau `HASIL` masih memuat OOF demo. Latih ulang model, atau ganti nama `HASIL`.
`id test = id sample: False`	`ID_COL` salah, atau test bukan file yang dipasangkan dengan sample.
`UnicodeDecodeError`, kolom jadi satu	Baris ber-`#` di sel "Baca data" `2_praproses` (`encoding`, `sep`).
Prediksi hampir satu kelas	Kelas timpang: `CLASS_WEIGHT = True` di `4_finetune`; baseline sudah memakai `class_weight="balanced"` dan pengali kelas.
OOF tinggi, leaderboard rendah	Curigai teks kembar train (isi `GROUP_COL` atau lihat temuan kembar di `1_eda`) dan pergeseran train–test (AUC adversarial di `1_eda`).
Topik berisi kata sampah	Tambah ke `EXTRA_STOPWORDS`, naikkan `MIN_DF`, turunkan `MAX_DF`.

7 Daftar cek

Sebelum 13.00

☐ susunan folder seperti Gambar 3
☐ `jupyter.bat` membuka JupyterLab
☐ rantai 1–7 pernah Run All di data demo
☐ `4_finetune` menulis `device: cuda`
☐ folder `outputs/final` demo tidak dipakai lagi

Sebelum meninggalkan PC

☐ tiga file submission tercatat: nama, skor OOF, skor leaderboard
☐ `6_topik`: `TOPIC_NAMES` sudah diisi
☐ `7_laporan_model` dijalankan sesudah model terakhir
☐ `8_ekspor.bat`, lalu baca `MANIFEST.md`
☐ screenshot leaderboard