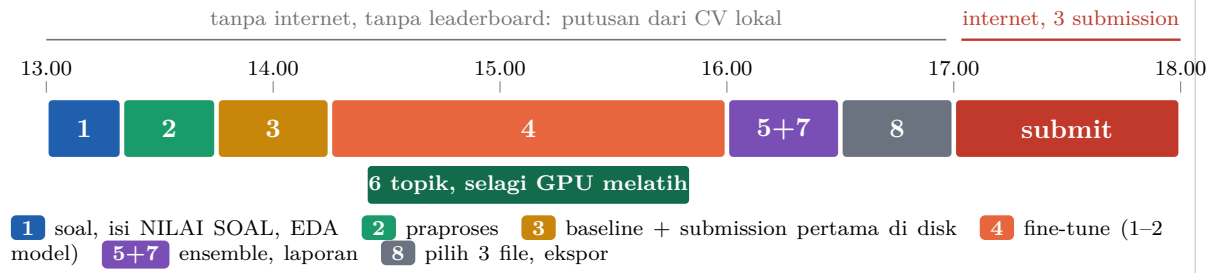
Petunjuk Akhir: final-pipeline

GEMASTIK XIX Penambangan Data • Rabu, 11 November 2026 • 13.00–18.00

Tebakan soal: **klasifikasi teks** (skor di Kaggle), single label atau multilabel, dan **topic modeling** (dipresentasikan). Langkah bernomor; nilai soal diisi di sel Konfigurasi tiap notebook.

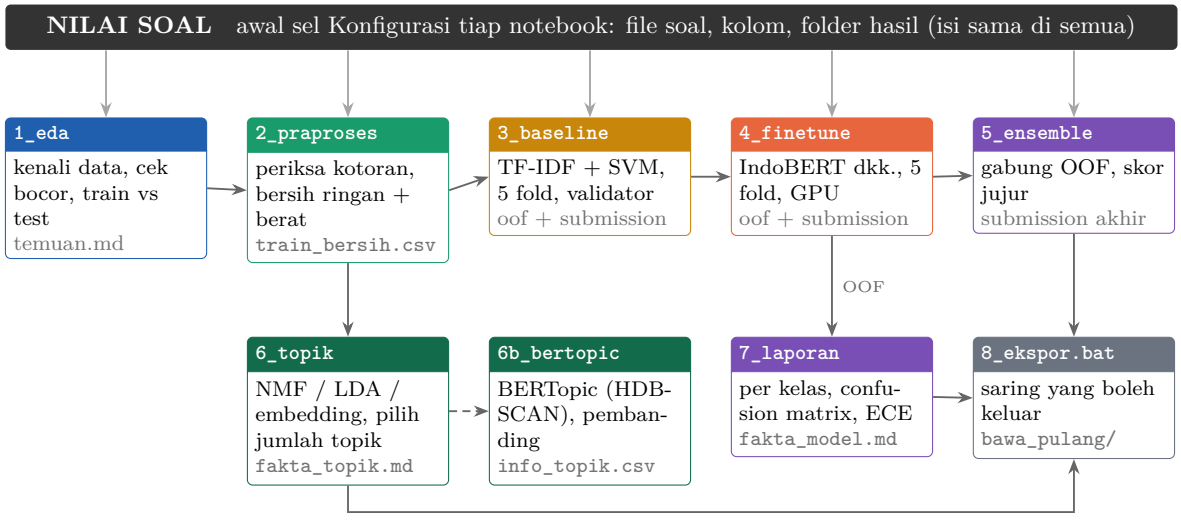
Gambar 1. Lima jam dalam satu garis (rencana, bukan aturan panitia)



1 Peta pipeline

Folder `final-pipeline` berisi salinan tujuh notebook repo yang sudah teruji, diberi nomor urut. Kodenya sama dengan `contoh/text/`; yang berbeda hanya path dan sel Konfigurasi, yang diawali blok **NILAI SOAL**. Tidak ada `konfig.py`: tiap notebook berdiri sendiri. Jalankan menurut nomor.

Gambar 2. Alur file dari soal sampai bahan presentasi



Gambar 3. Susunan folder yang wajib (path di notebook relatif)

```
C:/GEMASTIK/
  not-a-super-secret-weapon/   repo
    final-pipeline/   folder ini
      1_eda.ipynb ... 7_laporan_model.ipynb
      3m_, 4m_, 5m_ ...  multilabel
      8_ekspor.bat, jupyter.bat
      demo/, kamus/
  pretrained/   model (download_model.bat)
  .venv/   dibuat setup.bat
  outputs/final/   semua hasil
```

Buka: dobel klik `jupyter.bat` di folder ini.

Tidak butuh `data_latihan`: data demo dan kamus alay sudah ikut di sini.

Folder ini **ada di dalam repo**, jadi ikut `git clone` / `git pull`.

2 Yang diubah saat soal dibuka

Blok **NILAI SOAL** di awal sel Konfigurasi (sel kode pertama sesudah judul "Konfigurasi") di **setiap** notebook yang dijalankan. Tidak ada `konfig.py`; tiap notebook menyimpan nilainya sendiri, jadi **isi nilai yang sama di semua notebook**, terutama `HASIL`: notebook 3–7 membaca `<HASIL>/praproses/train_bersih.csv` buatan `2_praproses`, dan `HASIL` yang beda membuat file itu tidak ketemu. Ubah baris yang ada saja; jangan menyalin blok utuh dari notebook lain, karena tiap notebook hanya memuat variabel yang dipakainya (Tabel di bawah). Sesudah mengubah: *Restart Kernel and Run All*. Di bawah blok ada bagian "jalur final-pipeline" (path dari `HASIL`): tidak perlu diubah.

```
TRAIN_MENTAH = "C:/GEMASTIK/soal/train.csv"                          wajib
TEST_MENTAH  = "C:/GEMASTIK/soal/test.csv"                           wajib
SAMPLE_PANITIA = "C:/GEMASTIK/soal/sample_submission.csv"            wajib

ID_COL = "id"    TEXT_COLS = ["text"]    TARGET = "label"            wajib
SUBMIT_COL = TARGET                          bila nama di sample beda

HASIL = "../../outputs/lomba"                    ganti dari "final"
LANGUAGE, DATE_COL, GROUP_COL, TFIDF_BERAT, TOPIK_BERAT              bila perlu
```

notebook	baris di blok NILAI SOAL
1_eda	TRAIN_MENTAH TEST_MENTAH ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS DATE_COL LANGUAGE HASIL SCORING
2_praproses	TRAIN_MENTAH TEST_MENTAH ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS HASIL SCORING
3_baseline	SAMPLE_PANITIA ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS GROUP_COL DATE_COL HASIL TFIDF_BERAT
4_finetune	SAMPLE_PANITIA ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS GROUP_COL HASIL
5_ensemble	SAMPLE_PANITIA ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS HASIL
6_topik	ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS DATE_COL LANGUAGE HASIL TOPIK_BERAT
6b_topik_bertopic	TEXT_COLS TARGET SUBMIT_COL LABEL_COLS LANGUAGE HASIL
7_laporan_model	TEXT_COLS TARGET SUBMIT_COL LABEL_COLS HASIL
3m_baseline_multilabel	SAMPLE_PANITIA ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS HASIL TFIDF_BERAT
4m_finetune_multilabel	SAMPLE_PANITIA ID_COL TEXT_COLS TARGET SUBMIT_COL LABEL_COLS HASIL
5m_ensemble_multilabel	SAMPLE_PANITIA ID_COL TARGET SUBMIT_COL LABEL_COLS HASIL
9_figur_ppt.py	HASIL (baris atas file, bagian "Konfigurasi")
9b_slide.py	HASIL ID_COL TEXT_COLS TARGET (baris atas file, bagian "Konfigurasi")
8_ekspor.bat	baris set "HASIL=..."

Tiga hal di luar blok NILAI SOAL.

1. **Metrik.** Bawaannya F1 makro. Kalau soal memakai metrik lain, pindahkan # di baris return sel "Metrik" pada 3_baseline, 4_finetune, dan 5_ensemble (ketiganya harus sama).
2. **Pemisah dan encoding CSV.** Kalau pd.read_csv gagal atau kolom jadi satu, pakai baris ber-# di sel "Baca data" 2_praproses (sep=";", encoding="latin-1"). Notebook 3–7 membaca train_bersih.csv, jadi cukup dibetulkan di notebook 1 dan 2.
3. **Pola awalan/akhiran.** STRIP_PATTERNS di 2_praproses masih pola demo. Isi dari tabel "Awalan dan akhiran berulang" di notebook itu, atau kosongkan ([]).

3 Langkah demi langkah

Waktu di pojok kanan diukur pada gladi 10 November 2026 di laptop (RTX 5060 8 GB) dengan data demo SmSA: 11.000 teks latih, 3 kelas. Data lomba yang lebih besar atau lebih panjang akan lebih lama.

1_eda — demo 23 s

Tujuan	Tahu bentuk data sebelum memilih apa pun. Tidak mengubah file.
Lihat	Sebaran kelas, panjang teks, teks kembar dan kembar beda label, kekuatan tiap kolom (tanda bocor), AUC adversarial train vs test.
Luaran	<HASIL>/eda/temuan.md dan PNG. AMAN_NDA = True: tidak mencetak teks asli. Soal multilabel: bagian 7f (lihat bagian "Kalau soalnya multilabel").

2_praproses — demo 60 s

Tujuan Membuat `train_bersih.csv` dan `test_bersih.csv` yang dibaca semua notebook sesudahnya.

Ubah `STRIP_PATTERNS`; saklar `DROP_*` di bagian 7 (teks kembar beda label).

Lihat Tabel "Ukur": langkah mana yang menaikkan skor. Tiga baris `CEK` di sel terakhir harus `True`.

Awas Jumlah baris train bisa berkurang (kosong, kembar). Jangan jalankan ulang notebook ini sesudah ada OOF, kecuali semua model dilatih ulang.

3_baseline — demo 24 s, F1 OOF 0,860

Tujuan Submission pertama yang sah dan OOF pertama. Target: selesai sebelum 14.15.

Ubah `MODEL_NAME` tiap variasi (mis. `tfidf_logreg`), lalu pindahkan `#` di `CLASSIFIER`. Nama sama berarti OOF lama tertimpa.

Lihat Skor OOF dan baris terakhir validator: `MASALAH: 0`. Tulisan `PERINGATAN: SAMPLE_CSV masih file demo` berarti `SAMPLE_PANITIA` belum diisi.

Luaran `baseline/submission.csv`, `oof/oof_<nama>.npy`, `oof/percobaan.csv`.

4_finetune — demo 31 s per epoch per fold; 1 epoch F1 OOF 0,927

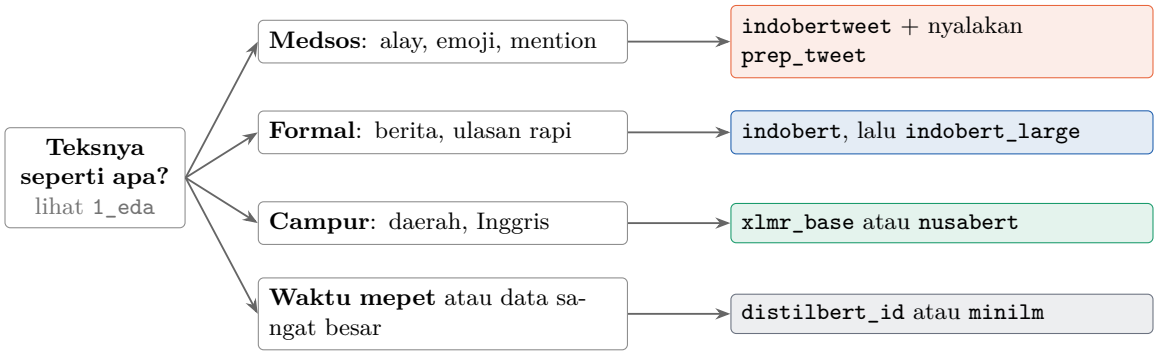
Tujuan Skor tertinggi. Zero-shot dan few-shot dilarang; fine-tune sendiri seperti ini boleh.

Ubah `PRETRAINED` + `MODEL_NAME` (Gambar 4); `MAX_LENGTH` dari tabel persentil token (ambil sekitar p95).

Uji dulu `FOLDS_TO_RUN = [0]` untuk mengukur waktu satu fold (OOF tidak disimpan), lalu kembalikan ke `None`. Waktu penuh kira-kira 5 kali satu fold. Gladi memakai 1 epoch (3 menit); bawaan 3 epoch, jadi kira-kira 8 menit di data demo.

Awas GPU hanya untuk satu notebook fine-tune pada satu waktu. Model *large*: `BATCH_SIZE = 8`, `ACCUM_STEPS = 2`, `GRAD_CHECKPOINT = True`.

Gambar 4. Memilih `PRETRAINED` di `4_finetune`



Dua model yang berbeda (mis. `indobert` dan `xlmr_base`) lebih berguna untuk ensemble daripada satu model dengan dua seed.

5_ensemble — demo 5 s

Tujuan Menggabung semua OOF di `oof/` dan menilai dengan skor jujur (bobot dicari di lipatan lain).

Lihat Sel "Putusan". Gabungan hanya dipakai bila naik sekurangnya `MIN_GAIN` (0,002); kalau tidak, notebook memilih model tunggal terbaik. Ikuti putusannya.

Luaran `ensemble/submission.csv`, `ablation.csv` (bahan slide).

6_topik dan 6b_topik_bertopic — demo 5 menit dan 80 s

Tujuan	Topic modeling untuk presentasi. `6_topik` membandingkan NMF, LDA, dan embedding+KMeans pada beberapa jumlah topik dengan koherensi NPMI, keragaman, dan kestabilan, lalu memilih sendiri.
Masukan	`<HASIL>/praproses/train_bersih.csv` dan `test_bersih.csv` (dari `2_praproses`; belum ada = jalankan `2_praproses` dulu). Dua kolom dipakai: `text` (bersih ringan) untuk embedding MiniLM `../../pretrained/minilm`, dan `text_tfidf` (bersih berat) untuk kata topik. Nama kolom mengikuti `TEXT_COLS` di blok NILAI SOAL `6_topik.ipynb`.
Kata topik	Saklar `TOPIK_BERAT` di blok NILAI SOAL `6_topik.ipynb`. `True` (bawaan): kata dari kolom `text_tfidf`, jadi slang sudah baku, imbuhan dibuang (stemming), dan "gak"/"tidak" atau "makanannya"/"makan" jadi satu kata. Kata jadi bentuk dasar ("layan", bukan "pelayanan"). `False`: kata dari kolom `text`, hanya stopword dibuang; pakai untuk teks baku atau Inggris, atau bila stemming merusak nama. Isi kamus slang: `kamus/kamus_alay_salsabila.csv` dan `kamus/kamus_slang.csv`. Urutan langkah berat: `HEAVY_STEPS` di sel bagian 4 `2_praproses.ipynb`; diubah = jalankan ulang `2_praproses` lalu `6_topik`.
Ubah	Di sel "Konfigurasi" `6_topik.ipynb`: `EXTRA_STOPWORDS` (kata umum yang mengotori topik, mis. `"sih"`), `TOPIC_COUNTS` bila jumlah topik yang wajar jauh dari 4–15, `METHODS`. Lalu di sel "Beri nama topik": `TOPIC_NAMES` sesudah membaca kata teratas (tulis bentuk wajar, mis. "pelayanan"), jalankan ulang dari sel itu ke bawah.
Kapan	Selagi `4_finetune` berjalan. NMF dan LDA memakai CPU. Metode `"embedding"` dan `6b` memakai MiniLM di GPU; bila VRAM penuh, hapus `"embedding"` dari `METHODS` dulu.
Luaran	Folder `<HASIL>/topik/`: `fakta_topik.md` (kalimat untuk slide), `01_..09_*.png` + `.csv` (pemilihan K, ukuran, kata teratas, awan kata, kemiripan, topik × kelas, train vs test, tren, peta 2D), `info_topik.csv`. `topik_dokumen.csv` (topik per baris) tetap di komputer lomba.
`6b`	Hanya pembanding, membaca `train_bersih.csv` kolom `text` (tanpa `TOPIK_BERAT`). BERTopic menentukan jumlah topik sendiri dan menyisakan topik −1. Luaran: `<HASIL>/bertopic/`.

7_laporan_model — demo 7 s

Tujuan	Bahan slide hasil klasifikasi dari OOF, tanpa GPU: skor tiap model, laporan per kelas, confusion matrix, pasangan kelas tertukar, keandalan (ECE).
Luaran	`laporan/fakta_model.md` dan 10 grafik. Jalankan sesudah model terakhir selesai.

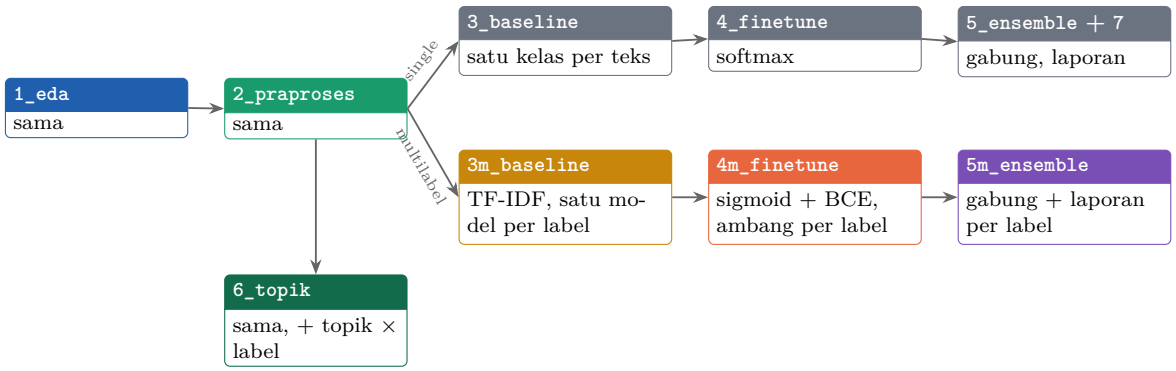
8_ekspor.bat — beberapa detik

Tujuan	Menyalin yang boleh keluar ke `outputs/bawa_pulang/` dan menolak sisanya.
Ubah	Baris `set "HASIL=..."` di `8_ekspor.bat` bila `HASIL` di notebook diganti (isi sama).
Lihat	`MANIFEST.md`: daftar yang disalin, yang ditolak, dan alasannya.

4 Kalau soalnya multilabel

Multilabel berarti satu teks boleh punya beberapa label sekaligus, dan target berupa beberapa kolom 0/1. Notebook 3, 4, 5, dan 7 **tidak** bisa dipakai untuk itu. Gantinya tiga notebook berakhiran `m`; EDA, praproses, dan topic modeling tetap notebook yang sama.

Gambar 5. Jalur single label dan jalur multilabel




```
LABEL_COLS = ["harga", "layanan", "kualitas"]
TARGET = "harga"
```

wajib untuk multilabel

satu label terpenting

- **`LABEL_COLS`** adalah daftar kolom label 0/1 di train. Selama isinya `None`, notebook `m` berhenti dengan pesan galat.
- **`TARGET`** tetap dibutuhkan `1_eda`, `2_praproses`, dan grafik "topik × kelas", yang hanya mengerti satu kolom kelas. Isi dengan satu label terpenting; kalau tidak diisi, dipakai label pertama.
- **Hasil** masuk `baseline_multilabel/`, `finetune_multilabel/`, `ensemble_multilabel/`, dan OOF ke `oof_multilabel/`. `8_ekspor.bat` sudah mengambilnya.
- **`6_topik`** menambah grafik `06b_topik_x_label.png`: porsi teks berlabel di tiap topik beserta lift-nya, plus kalimatnya di `fakta_topik.md`.
- **`1_eda`** menjalankan bagian **7f. Multilabel** (dilewati bila `LABEL_COLS = None`): porsi tiap label, jumlah label per teks, label yang sering muncul bersama (P(kolom | baris)), panjang teks per label, teks kembar dengan kombinasi label berbeda. Luaran di `<HASIL>/eda/`: `07f_multilabel.png`, `07f_panjang_per_label.csv`, kalimatnya di `temuan.md`. Kolom label yang bukan 0/1 menghentikan bagian ini dengan pesan galat.
- **Mencoba dulu:** di bagian bawah blok NILAI SOAL tiap notebook ada baris ber-`#` untuk data demo CASA (6 label). Buka `#` di semua notebook yang dijalankan (baris yang variabelnya tidak ada di notebook itu tidak berpengaruh).

`3m_baseline_multilabel` — demo CASA 5 s, F1 makro OOF 0,862

Tujuan	Submission multilabel pertama dan OOF pertama, tanpa GPU.
Ubah	`MODEL_NAME` tiap variasi; `MIN_ONE_LABEL = True` bila tiap teks pasti punya minimal satu label.
Lihat	Tabel ambang per label dan **`MASALAH: 0`**. Baris `nilai label selain 0/1` harus 0.

`4m_finetune_multilabel` — demo CASA 150 s (5 epoch, 5 fold), F1 makro OOF 0,924

Tujuan	Skor tertinggi: satu logit per label, loss BCE, ambang per label dari OOF.
Ubah	`PRETRAINED` + `MODEL_NAME`; `POS_WEIGHT = True` untuk label langka; `EPOCHS` (bawaan 5, untuk data kecil; data besar cukup 3).
Awas	Hanya memakai kolom teks pertama di `TEXT_COLS`. Lipatannya sama dengan `3m` (`KFold` seed 42), jadi jangan ubah `SPLIT_SEED`.

5m_ensemble_multilabel — demo CASA 9 s

Tujuan	Menggabung OOF `3m` dan `4m`, menulis submission akhir, sekaligus laporan untuk slide.
Lihat	Sel "Putusan". Rata-rata dipakai hanya bila skor jujur naik sekurangnya `MIN_GAIN`; di demo yang dipilih model tunggal `ml_indobert` (0,919 lawan rata-rata 0,913).
Luaran	`submission.csv`, `fakta_multilabel.md`, skor per label, jumlah label per teks, label yang muncul bersama.

Label ditulis dalam satu kolom (misalnya `"harga, layanan"`)? Notebook `m` butuh kolom 0/1. Pecah dulu di sel baru paling atas `2_praproses`, sesudah sel "Baca data", lalu isi `LABEL_COLS` dengan nama kolom yang muncul:

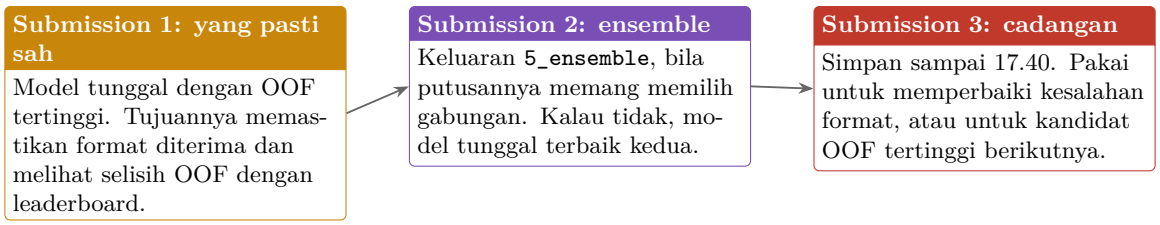
```
pecah = train["label"].str.replace(" ", "").str.get_dummies(sep=",")
train = pd.concat([train, pecah], axis=1)
print(pecah.columns.tolist())
```

Potongan ini tidak ikut diuji dalam rantai; cek hasil `print`-nya sebelum lanjut. Format submission multilabel juga bisa berbeda dari kolom 0/1 (ikuti sample panitia).

5 Jam terakhir: tiga submission

Empat jam pertama tidak ada leaderboard. Pilih file dari skor OOF dan dari validator, bukan dari perasaan.

Gambar 6. Urutan tiga submission (saran)



Sebelum mengunggah tiap file:

☐ validator di notebook penghasilnya menulis `MASALAH: 0` dan tidak ada `PERINGATAN: SAMPLE_CSV masih file demo`;

☐ jumlah baris dan urutan id sama dengan sample panitia (dicek validator);

☐ sebaran kelas prediksi masuk akal, tidak satu kelas saja (dicetak validator);

☐ nama file dan nama kolom persis seperti yang diminta soal.

Leaderboard publik hanya sebagian data test. Selisih kecil di sana belum tentu nyata; kalau OOF dan leaderboard tidak sepakat untuk selisih kecil, pegang OOF.

6 Yang boleh keluar dari PC lomba

Boleh dibawa

- PNG grafik dan tabel ringkas
- `temuan.md`, `fakta_topik.md`, `fakta_model.md`
- notebook, file submission, model
- screenshot

Semuanya dikumpulkan `8_ekspor.bat`.

Dilarang keluar

- teks asli atau baris data
- `train_bersih.csv`, `test_bersih.csv`
- file per baris: OOF (`.npy`), `topik_dokumen.csv`, `pseudo_label.csv`
- output sel yang mencetak teks

Slide dibuat di laptop tanpa akses data, jadi setiap angka yang ingin disebut harus sudah ada di tiga file `.md` di atas atau di PNG. Kalau ada angka yang kurang, tambahkan ke notebook *sebelum* meninggalkan PC lomba.

7 Kalau macet

Gejala	Tindakan
`CUDA out of memory`	`BATCH_SIZE = 8` dan `ACCUM_STEPS = 2`; kecilkan `MAX_LENGTH`; tutup kernel notebook lain yang memakai GPU (termasuk `6_topik`).
`device: cpu` di `4_finetune`	Driver NVIDIA belum cocok (torch cu128 butuh driver 570 ke atas). Selagi diperbaiki, kerjakan variasi `3_baseline`.
Satu fold terlalu lama	`distilbert_id` atau `minilm`; `EPOCHS = 2`; `PATIENCE = 2` dengan `EVALS_PER_EPOCH = 2`.
`TIDAK ADA OOF YANG COCOK`	OOF dibuat dari train yang lain: `2_praproses` dijalankan ulang atau `HASIL` masih memuat OOF demo. Latih ulang model, atau ganti nama `HASIL`.
`id test = id sample: False`	`ID_COL` salah, atau test bukan file yang dipasangkan dengan sample.
`UnicodeDecodeError`, kolom jadi satu	Baris ber-`#` di sel "Baca data" `2_praproses` (`encoding`, `sep`).
Prediksi hampir satu kelas	Kelas timpang: `CLASS_WEIGHT = True` di `4_finetune`; baseline sudah memakai `class_weight="balanced"` dan pengali kelas.
OOF tinggi, leaderboard rendah	Curigai teks kembar train (isi `GROUP_COL` atau lihat temuan kembar di `1_eda`) dan pergeseran train–test (AUC adversarial di `1_eda`).
Topik berisi kata sampah	Di sel "Konfigurasi" `6_topik.ipynb`: tambah ke `EXTRA_STOPWORDS`, naikkan `MIN_DF`, turunkan `MAX_DF`. Kata dasar aneh (stemming salah, mis. nama tempat terpotong): `TOPIK_BERAT = False` di blok NILAI SOAL `6_topik.ipynb`, lalu Run All `6_topik`.
`KeyError: 'text_tfidf'` di `6_topik`	`<HASIL>/praproses/train_bersih.csv` tidak punya kolom `<teks>_tfidf` (file lama atau `TEXT_COLS` berubah): Run All `2_praproses.ipynb`, lalu `6_topik.ipynb`.

8 Daftar cek

Sebelum 13.00

☐ susunan folder seperti Gambar 3
☐ `jupyter.bat` membuka JupyterLab
☐ rantai 1–7 pernah Run All di data demo
☐ `4_finetune` menulis `device: cuda`
☐ folder `outputs/final` demo tidak dipakai lagi

Sebelum meninggalkan PC

☐ tiga file submission tercatat: nama, skor OOF, skor leaderboard
☐ `6_topik`: `TOPIC_NAMES` sudah diisi
☐ `7_laporan_model` dijalankan sesudah model terakhir
☐ `8_ekspor.bat`, lalu baca `MANIFEST.md`
☐ screenshot leaderboard